

Graphical Abstract

A Multi-uav path planning method based on DMP hybrid reinforcement learning and safety constraints

Harry Kane

Highlights

A Multi-uav path planning method based on DMP hybrid reinforcement learning and safety constraints

Harry Kane

- Research highlight 1
- Research highlight 2

A Multi-uav path planning method based on DMP hybrid reinforcement learning and safety constraints

Harry Kane

FC Bayern Munich, , Munich, 123456, , Germany

Abstract

Abstract text.

Keywords:

1. Introduction

低空复杂环境中的多无人机协同作业正在成为巡检, 搜救, 园区配送和灾害评估等任务的重要执行方式. 一个典型的工程系统通常由地面任务平台和多架无人机构成: 任务平台根据巡检设备位置, 搜索区域, 物资投送点或灾情评估区域为各无人机分配任务目标, 无人机则在城市低空, 园区, 灾后现场, 森林和工业厂区等环境中自主飞向目标. 这些环境中往往同时存在建筑物, 树木, 设备, 临时障碍物和移动目标, 且现场状态会随人员, 车辆, 风场或任务进程变化. 因此, 工程上可以合理获得任务目标点和基本飞行边界, 却很难在飞行前获得完整, 准确且实时更新的三维可通行地图.

在上述工程背景下, 多无人机路径规划的核心矛盾不是是否知道任务目标, 而是知道任务目标后如何在未知或部分未知的现场结构中安全推进. 具体而言, 每架无人机可以获得自身位置和任务目标点在统一导航坐标系下的位置, 但目标点只提供任务级方向引导, 并不等价于从当前位置到目标之间的全局可行路径. 沿途障碍是否临时出现, 通道是否被遮挡, 邻近无人机会如何占用局部空间, 这些信息通常只能通过机载传感器和有限邻近状态在飞行过程中逐步获得. 因此, 本文面向的是任务目标已知但完整可通行结构未知的多无人机协同导航问题.

这一问题对实际飞行提出了比单纯到达目标更严格的要求. 首先, 环境不完全已知使无人机不能完全依赖离线规划结果; 其次, 多架无人机同时飞行时需要同时处理环境避障和机间避让, 单机安全并不等价于系统安全; 再次, 复杂环境中的大量危险试错在工程上难以接受; 最后, 飞行轨迹还需要保持平滑和稳定, 以避免过大的转向, 震荡和控制负担. 在计算资源, 通信条件和传感范围均受限的条件下, 更实际的做法是让无人机主要依靠局部感知和有限邻近信息进行实时决策.

在这样的工程条件下, 直接让强化学习策略从原始局部观测中学习飞行动作会带来较高的探索风险和不安定的轨迹行为. 更实际的做法是先从局部观测中提取具有安全意义的候选引导点, 再结合无人机自身状态和邻近无人机状态选择合适的短时目标, 最后通过平滑的运动生成方式执行. 本文的工作正是围绕这一需求展开, 目标是在不依赖完整全局地图的前提下, 提高多无人机在复杂动态环境中的局部导航安全性和执行稳定性.

为此, 本文提出一种异步分层路点-DMP强化学习导航框架. 上层候选点提议模块基于当前状态, 任务目标方向和局部环境信息, 低频生成未来若干个候选引导点. 这些候选引导点不被视为必须严格跟踪的完整轨迹, 而是进入pending goal buffer, 由后续GAT筛选模块和下层策略根据局部风险, 任务进度和DMP执行相位进行选择, 跳过, 保留或偏移.

该框架的关键在于处理候选点提议, 子目标筛选和下层DMP执行之间的时间尺度冲突. 若候选点频繁刷新并直接替换当前目标, DMP运动基元可能在尚未执行完成时被打断, 从而造成轨迹不连续, 目标切换抖动和训练非平稳. 因此, 本文采用受控异步机制: 当前DMP仅执行active goal, 新生成的候选引导点进入pending goal buffer; 只有当DMP phase接近结束, 当前目标已经到达, 目标区域风险过高, 执行超时或进度停滞时, 才允许从pending goals中切换新的active goal. 这种机制使上层候选提议与下层DMP轨迹执行能够在不同时间尺度下稳定协同.

本文的主要贡献可概括为:

- 提出一种异步分层路点-DMP强化学习框架, 使候选点提议, GAT筛选与下层DMP运动基元执行能够在不同时间尺度下稳定协同.

- 设计一种基于GAT的候选子目标筛选与结构化动作空间, 将局部导航分解为候选路点选择, 目标点偏移和DMP residual forcing调制, 避免策略直接输出低层控制量带来的学习困难.
- 引入DMP相位感知的子目标切换机制, 通过active goal维护, pending goal buffer和风险触发提前终止, 缓解DMP执行中断, 目标切换抖动和训练非平稳问题.

2. Related Work

2.1. Multi-UAV Path Planning

2.2. Reinforcement Learning for Motion Planning

2.3. Safety-Constrained Reinforcement Learning

3. Preliminaries

本节主要介绍本文方法所依赖的基础建模, 包括多智能体任务定义, 动态障碍环境建模, 动态运动基元以及安全约束表征.

3.1. Problem Formulation

为准确描述本文面向的主要研究问题, 将多智能体强化学习路径规划任务建模为一个多智能体马尔可夫博弈过程. 马尔可夫博弈是马尔可夫决策过程在多智能体场景下的扩展, 用于刻画多个智能体在多个动作空间中的动作决策过程. 一个马尔可夫博弈过程可以由下式表示:

$$\mathcal{G} = \langle \mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i \in \mathcal{N}}, P, \{r_i\}_{i \in \mathcal{N}}, \gamma \rangle \quad (1)$$

其中, $\mathcal{N}$ 表示当前场景下的智能体集合, $\mathcal{S}$ 表示全局状态空间, $\mathcal{A}_i$ 表示第 i 个智能体的动作空间, P 表示状态转移概率, r_i 表示第 i 个智能体的奖励函数, $\gamma \in [0, 1)$ 表示折扣因子. 对每个时间步, 各个智能体依据当前的环境观测选择自身动作, 所有智能体的联合动作共同决定环境状态转移与智能体获得的即时奖励大小. 智能体的目标是在多智能体联合交互的过程中学习最优策略, 最大化联合期望回报.

本研究中, 考虑一种多智能体在存在多类障碍物的有边界环境内的实时路径规划过程. 场景存在的障碍物类型由集合 $\mathbf{O}$ 表示:

$$\mathbf{O} = \{\mathbf{O}_{static}, \mathbf{O}_{dynamic}\} \quad (2)$$

其中, $\mathbf{O}_{static}$ 表示场景中的静态障碍物, 其差异主要体现在几何外形上. 根据几何形状的不同, 本文将静态障碍物建模为圆柱体, 球体和立方体三类, 用于模拟环境中的树木, 建筑物等固定障碍物. $\mathbf{O}_{dynamic}$ 表示环境中的动态飞行障碍物, 该类障碍物以随机方向和随机速度在环境中进行直线段运动.

3.2. Dynamic Movement Primitives

3.3. Safety Constraint Representation

4. Methodology

本节介绍所提出的异步分层路点-DMP强化学习导航框架. 该框架针对部分可观条件下的多无人机局部导航问题, 通过局部风险感知的候选点提议, GAT-based subgoal filtering, pending goal buffer, 目标偏移, DMP residual forcing调制和phase-aware子目标切换, 实现候选子目标选择与平滑轨迹执行之间的稳定协同.

4.1. Overview

4.2. sensor Sector-wise Safety-margin Reference Point Proposal

复杂动态环境中的无引导探索通常具有较高的样本复杂度和安全风险. 为降低下层策略直接从原始 sensor 观测中学习子目标选择的难度, 本文在上层引入基于局部感知的参考点提议机制. 该模块每隔固定周期 T 根据当前 sensor 观测和任务目标方向提议一组短时域参考点. 这些参考点仅作为 pending goal buffer 的候选输入, 经GAT编码采样之后, 交由下层DMP执行模块进一步优化跟踪.

给定 t 时刻智能体位置 $\mathbf{x}_t$, 速度 $\mathbf{v}_t$, 局部坐标系下的 sensor 点云 $\mathcal{O}_t = \{\mathbf{o}_i\}_{i=1}^N$ 和当前任务目标位置 $\mathbf{p}_{task,t} \in \mathbb{R}^3$, 上层模块首先将局部观测划分为有限个方向扇区, 并在每个扇区内构造 CBF-inspired 安全裕度. 随后, 系统

仅在满足当前观测安全裕度的扇区内提议参考点, 并根据安全裕度, 任务推进性, 运动连续性和可用前视距离选取 top- K 个候选. 本文将生成的参考点集合定义为

$$\mathcal{G}_t = \{\mathbf{g}_t^1, \mathbf{g}_t^2, \dots, \mathbf{g}_t^K\}. \quad (3)$$

其中, $\mathbf{g}_t^k$ 表示第 k 个候选参考点, K 表示子目标缓存集合中保留的候选数量. 生成后的 $\mathcal{G}_t$ 被写入缓存 $\mathcal{B}_t$, 而不是直接替换当前 DMP 正在执行的 active goal. 这种异步写入方式保留了上层局部引导信息, 同时避免高频目标切换打断下层轨迹执行.

为同时编码目标点的几何位置和任务类型, 本文将第 t 个时间步的任务点表示为增广目标向量:

$$\tilde{\mathbf{g}}_t = [\mathbf{p}_{\text{task},t}^\top, I_{\text{task},t}]^\top, \quad I_{\text{task},t} \in \{0, 1\}. \quad (4)$$

其中, $\mathbf{p}_{\text{task},t} \in \mathbb{R}^3$ 表示当前任务点的三维位置, $I_{\text{task},t}$ 为任务点类型的二值标记. 本文令 $I_{\text{task},t} = 0$ 表示中间路径点, $I_{\text{task},t} = 1$ 表示任务终点. 后续涉及距离, 方向和到达条件的计算时, 仅使用几何位置 $\mathbf{p}_{\text{task},t}$; 增广表示 $\tilde{\mathbf{g}}_t$ 主要作为策略输入特征, 用于帮助智能体区分不同类型任务点的执行语义.

4.2.1. sensor Sector Decomposition

首先, 将每个 sensor 点 $\mathbf{p}_i = (x_i, y_i, z_i)$ 转换到以智能体当前位置为原点的局部坐标系, 并将可观测空间离散为 M 个方向扇区:

$$\mathcal{U}_t = \{\mathbf{u}_t^1, \mathbf{u}_t^2, \dots, \mathbf{u}_t^M\}. \quad (5)$$

其中, $\mathbf{u}_t^m$ 表示第 m 个候选方向, 并对应一个局部观测扇区 $\mathcal{S}_t^m$. 该扇区中的点云集合表示为

$$\mathcal{P}_t^m = \{\mathbf{p}_i \in \mathcal{P}_t \mid \mathbf{p}_i \in \mathcal{S}_t^m\}. \quad (6)$$

对于每个扇区, 本文统计最近障碍距离和点云数量:

$$d_{t,m}^{\min} = \min_{\mathbf{p}_i \in \mathcal{P}_t^m} \|\mathbf{p}_i\|_2, \quad c_{t,m} = |\mathcal{P}_t^m|. \quad (7)$$

若某一扇区在 sensor 可靠探测范围内没有有效点云返回, 本文将其视为当前观测下的局部空旷方向, 并令 $d_{t,m}^{\min} = r_{\text{sensor}}$, $c_{t,m} = 0$, 其中 r_{sensor} 表示 sensor 可靠探测半径. 该约定避免将局部空旷区域和不可观测区域混同. 对于接近观测边界或近距离障碍的方向, 后续通过前视步长截断进行保守处理. 这种扇区表示不描述完整环境结构, 仅用于从当前 sensor 中提取有限数量的方向安全信息.

4.2.2. CBF-inspired Sector Safety Margin

基于控制障碍函数的安全集思想, 本文为每个局部扇区定义一个 CBF-inspired safety margin. 对于第 m 个扇区, 安全裕度定义为

$$h_t^m = d_{t,m}^{\min} - r_{\text{safe}} - \tau_v \|\mathbf{v}_t\|_2. \quad (8)$$

其中, r_{safe} 为最小安全距离, $\tau_v \|\mathbf{v}_t\|_2$ 表示由当前速度引入的保守制动距离. 当智能体速度较大时, 候选参考点需要更大的前向安全余量; 当最近障碍距离较小时, 该扇区的安全裕度降低. 若 $h_t^m > 0$, 则方向 $\mathbf{u}_t^m$ 在当前观测下具有局部安全余量; 若 $h_t^m \leq 0$, 则该方向不用于参考点提议.

为便于后续候选点排序, 本文将安全裕度归一化为

$$\bar{h}_t^m = \text{clip} \left(\frac{h_t^m}{h_{\max}}, 0, 1 \right). \quad (9)$$

其中, $h_{\max}$ 为归一化尺度. $\bar{h}_t^m$ 仅表示当前观测下的局部参考点提议裕度, 不表示完整轨迹满足控制障碍函数的前向不变性.

4.2.3. Sector-wise Reference Point Proposal

为避免参考点全部落入局部安全但任务进展不足的方向, 本文进一步引入任务推进方向:

$$\hat{\mathbf{d}}_t = \frac{\mathbf{p}_{\text{task},t} - \mathbf{x}_t}{\|\mathbf{p}_{\text{task},t} - \mathbf{x}_t\|_2}. \quad (10)$$

对于候选方向 $\mathbf{u}_t^m$, 其任务推进一致性定义为

$$A_t^m = (\mathbf{u}_t^m)^\top \hat{\mathbf{d}}_t. \quad (11)$$

其中, A_t^m 越大表示该方向越有利于接近当前任务目标. 需要强调的是, $\hat{\mathbf{d}}_t$ 仅作为弱目标引导, 不表示智能体必须沿该方向直接运动.

对于满足 $h_t^m > 0$ 的安全扇区, 本文根据安全裕度确定参考点前视步长:

$$\tilde{s}_t^m = \text{clip}(\eta h_t^m, s_{\min}, s_{\max}), \quad s_t^m = \min(\tilde{s}_t^m, d_{t,m}^{\min} - r_{\text{safe}}, r_{\text{sensor}}, s_{\max}). \quad (12)$$

其中, η 为比例系数, $s_{\min}$ 和 $s_{\max}$ 分别为参考点前视距离的下界和上界. $\tilde{s}_t^m$ 表示由安全裕度得到的期望前视步长, s_t^m 表示经过当前观测边界截断后的实际参考点步长. 第二项约束用于避免参考点被放置到当前扇区最近障碍物之后, 第三项约束用于避免参考点超出 sensor 可靠探测范围, 第四项进一步保持参考点前视距离不超过预设上界. 随后, 每个安全扇区生成一个候选参考点:

$$\mathbf{g}_t^m = \mathbf{x}_t + s_t^m \mathbf{u}_t^m. \quad (13)$$

同时, 为鼓励候选点在安全前提下保持足够的短时引导长度, 本文定义可用前视距离因子:

$$L_t^m = \text{clip}\left(\frac{s_t^m}{s_{\max}}, 0, 1\right). \quad (14)$$

其中, L_t^m 越大表示该方向能够提供更充分的局部前视空间. 该项不改变安全扇区的判定, 仅在安全候选之间进行排序时偏好具有更长可用前视距离的参考点.

为选取固定数量的候选参考点, 本文定义提议引导点得分:

$$S_t^m = w_h \bar{h}_t^m + w_g A_t^m + w_v (\mathbf{u}_t^m)^\top \hat{\mathbf{v}}_t + w_l L_t^m. \quad (15)$$

其中, $\hat{\mathbf{v}}_t$ 为当前速度方向, w_h , w_g , w_v 和 w_l 分别为安全裕度, 任务推进性, 运动连续性和可用前视距离的权重. 根据式 (??) 从所有安全扇区中选取得分最高的 top- K 个参考点, 得到 $\mathcal{G}_t$. 该模块只在参考点提议阶段引入当前 sensor 观测下的局部候选点, 后续经GAT过滤模块处理后作为中间引导引入下层跟踪过程.

4.3. GAT-based Subgoal Filtering Mechanism

在候选子目标进入 DMP-RL 执行器之前, 本文首先对上层引导模块生成的局部路点进行过滤与筛选, 以规避短时引导的非全局最优与参数敏感问题. 在实际训练过程中, 候选子目标的可用性不仅取决于其几何位置, 还与智能体当前运动状态, 局部感知结果以及周围其他智能体的运动状态密切相关. 为显式建模这些要素之间的关系, 本节引入图注意力网络(Graph Attention Network, GAT)构建候选子目标筛选模块. 该模块将候选路点, 智能体状态和其他智能体运动状态组织为图结构, 并通过注意力权重评估不同候选子目标在安全性, 可达性和任务推进效率上的相对重要性, 从而为后续 active goal 选择提供更稳定的候选集合.

4.3.1. Path-Aware Candidate Set Formulation

$$\mathcal{G}_c^i = \{g_c^1, g_c^2, g_c^3, \dots, g_c^n\} \quad (16)$$

将候选点, 我方智能体和临近友方智能体建模为一个异构图. 对当前任务, 其图结构可被描述为:

$$\mathcal{H}_t = (\mathcal{V}_t, \mathcal{E}_t, \mathcal{X}_t, \mathcal{Z}_t) \quad (17)$$

式中, $\mathcal{H}_t$ 表示候选目标动态图, $\mathcal{V}_t$ 表示图节点集合, $\mathcal{E}_t$ 表示边集合, $(X)_t$ 表示节点特征, $\mathcal{Z}_t$ 表示边特征.

图节点集合包含了当前异构图中包含的全部节点, 可以由下式表示:

$$\mathcal{V}_i^t = \{\mathbf{v}_{null}^t, \mathbf{v}_{agent}^t, \mathbf{v}_{align}^t, \mathbf{v}_1^t, \dots, \mathbf{v}_K^t\} \quad (18)$$

式中, $\mathbf{v}_{null}$ 表示空引导节点, 即当前时刻不需要引入局部引导, 直接选择目标位置即可获取最高的收益; $\mathbf{v}_{agent}$ 表示自身智能体节点, $\mathbf{v}_1, \dots, \mathbf{v}_K$ 表示当前时刻生成的 K 个候选引导节点. $\mathbf{v}_{agent}$ 与所有引导节点连接, 其不参与最终候选选择, 只提供当前时刻的智能体信息; $\mathbf{v}_{align}$ 表示友方智能体节点, 其与临近的候选节点相连, 主要将友方智能体位置纳入考量.

4.3.2. local conflict-aware heterogeneous candidate graph

在图神经网络中, 节点特征通常用于刻画节点自身的属性信息, 为后续消息传递与注意力权重计算提供基础. 考虑到本文构建的节点建模方式, 节点特征应能够反应局部几何信息, 风险信息与任务相关属性. 具体而言, 本文考虑的节点特征设计如下所示:

1. 空引导节点 $\mathbf{v}_{null}$: 该节点表示当前时刻不需要考虑额外的引导点, 直接将终点作为引导. 其特征向量可被设计为:

$$h_{null}^t = [\theta_t^{goal}, r_t^{goal}, s_t^{goal}] \quad (19)$$

式中, θ_t^{goal} 表示目标点相对机体坐标系的角度, r_t^{goal} 表示目标点相对机体坐标系的剩余距离, s_t^{goal} 表示该节点相对方向的安全评分, 由 ?? 计算. 我们没有在这部分引入目标点类别增广标记, 旨在让智能体在学习过程中理解不同引导点类型.

2. 智能体节点 $\mathbf{v}_{agent}$: 该节点用于引入智能体自身状态与信息. 其特征向量设计如下式所示:

$$h_{agent}^t = [v_i^t, r_i^t, \theta_i^t, v_i^{t-1}, \mathcal{S}_i^t] \quad (20)$$

式中, v_i^t 表示机体当前速度向量, r_i^t, θ_i^t 分别表示目标点相对距离和位置; v_i^{t-1} 表示上一时刻的运动向量, $\mathcal{S}_i^t$ 表示当前时刻各个sensor扇区的风险评分.

3. 候选引导节点 $\mathbf{v}_1 \dots \mathbf{v}_K$: 该节点用于引入引导节点信息, 为GAT建模过程提供依据与参考.

$$h_k^t = [p_k^t, \|p_k^t\|_2, \theta_k, l_k, s_k^t] \quad (21)$$

式中, p_k^t 表示候选参考点在机体坐标下的位置, 其二范数表示距离; θ_k 表示其到相对于机体坐标系的sensor区间标记, l_k 表示当前候选点相对任务目标的推进距离, s_k^t 表示当前方向的风险评分.

4. 友方节点 $\mathbf{v}_{align_i}$: 该节点引入当前智能体或候选引导节点附近的友机信息, 帮助策略理解场景中存在的其他智能体行为, 规避机间冲突行为.

$$h_{align_i}^t = [\theta_{align_i}^t, r_{align_i}^t, v_{align_i}^t] \quad (22)$$

式中, $\theta_{align_i}^t$ 表示当前友方节点的相对方位角, $r_{align_i}^t$ 表示相对当前智能体的距离, v_{align_i} 表示相对速度向量.

完成图结构中的节点设计后, 还需进一步构造节点之间的边连接关系, 从而有效刻画不同类型节点之间的信息传递关系. 本文构建的边连接并不表示真实的物理连接, 只描述不同节点之间的信息传递关系. 具体而言, 本文面向的异构图中的主要连接方式包含agent-proposal, proposal-align两类, 分别描述当前智能体与候选点, 候选点与其他友方智能体之间的交联关系:

1. agent-proposal边特征: 该部分主要刻画智能体状态与候选点之间的交联关系, 具体设计为:

$$e_{agent,k}^t = [s_{smooth,k}^t] \quad (23)$$

式中, $s_{smooth,k}^t$ 用于衡量当前智能体运动方向与候选点方向之间的平滑程度, 其具体计算方式为:

$$s_{smooth,k}^t = \frac{(\mathbf{v}_i^t)^\top (\mathbf{g}_k^t - \mathbf{x}_i^t)}{\|\mathbf{v}_i^t\|_2 \|\mathbf{g}_k^t - \mathbf{x}_i^t\|_2 + \varepsilon} \quad (24)$$

2. proposal-align边特征: 用于刻画当前候选点与临近友方智能体的时空占据情况. 对与当前候选点距离小于 d_{align} 的友方智能体构建, 具体设计为:

$$e_{k,align_j}^t = [\hat{t}_{k,j}^t, \hat{d}_{k,j}^t] \quad (25)$$

式中, $\hat{t}_{k,j}^t$ 表示选择该路点后的预计最小相遇时间, $\hat{d}_{k,j}^t$ 表示对应时刻的预计最小间距.

4.3.3. risk-aware edge-enhanced GAT selector

按照上述规则构建异构图 $\mathcal{H}_t$, 其节点集合与边集合分别为:

$$\mathcal{V}_t = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_i\} \quad (26)$$

$$\mathcal{E}_t = \{\epsilon_1, \epsilon_2, \dots, \epsilon_i\} \quad (27)$$

为确保执行GAT时的特征维度匹配, 上述节点特征与边特征均由MLP投影到相同的隐空间大小, 即:

$$\mathbf{h}_i^0 = \phi_{\tau(i)}(h_i^t) \in \mathbb{R}^{d_h}, \quad \mathbf{z}_{ij}^t = \psi_{\rho(i,j)}(e_{ij}^t) \in \mathbb{R}^{d_e}. \quad (28)$$

式中, $\tau(i)$ 表示节点 i 的节点类型, $\rho(i,j)$ 表示边 (i,j) 的边类型. $\phi_{\tau(i)}(\cdot)$ 与 $\psi_{\rho(i,j)}(\cdot)$ 分别表示节点类型相关和边类型相关的MLP映射函数. 该映射使不同类型节点与不同类型边在进入GAT计算前具有统一的隐空间维度.

受Edge-Enhanced Graph Attention和多智能体图决策方法启发, 本文将候选路线之间的几何可达性与风险代价编码为图结构的边特征, 构建risk-aware edge-enhanced GAT selector, 将边特征纳入考量. Ra-EGAT运算过程可以被表示为:

$$\eta_{ij}^l = \text{LeakyReLU}(\mathbf{a}^\top [W_h \mathbf{h}_i^l \| W_h \mathbf{h}_j^l \| W_e \mathbf{z}_{ij}^t]) \quad (29)$$

$$\alpha_{ij}^l = \frac{\exp(\eta_{ij}^l)}{\sum_{m \in \mathcal{N}(i)} \exp(\eta_{im}^l)} \quad (30)$$

其中, $\mathcal{N}(i)$ 表示节点 i 的邻居节点集合. 对于候选引导节点, 其邻居主要包括智能体节点以及满足局部距离约束的友方节点, 因此 agent-proposal 边与 proposal-align 边均可通过 $\mathbf{z}_{ij}^t$ 参与注意力权重计算. 经过EGAT更新后的候选点节点特征可被表示为:

$$\mathbf{h}_i^{l+1} = \sigma \left(\sum_{j \in \mathcal{N}(i)} \alpha_{ij}^l W_v \mathbf{h}_j^l \right) \quad (31)$$

节点状态更新后, 聚合所有候选目标的节点特征可得:

$$\mathcal{V}_{sel}^t = \{\mathbf{v}_{null}^t, \mathbf{v}_1^t, \dots, \mathbf{v}_K^t\} \quad (32)$$

引入MLP对特征矩阵进行打分, 得到最终节点输出:

$$\mathbf{g}_{GAT} = \operatorname{argmax}(\operatorname{softmax}(\psi_{out}(\mathcal{V}_{set}^t))) \quad (33)$$

4.4. A DMP based method for UAV navigation

DMP的优势在于能够生成平滑且具有收敛特性的运动轨迹. 为将其融入多无人机强化学习导航任务, 本文将DMP作为低层动作生成器, 将强化学习策略的学习目标从直接拟合低层控制量转化为对DMP轨迹的目标调制和强制力调制. 对于单个自由度, DMP的二阶点动态模型可写为:

$$\tau \dot{z} = \alpha_z(\beta_z(g - y) - z) + f(s), \quad (34)$$

$$\tau \dot{y} = z. \quad (35)$$

其中, y 表示当前自由度的位置, z 表示缩放后的速度状态, g 表示当前自由度的目标值, τ 为时间尺度参数, α_z 和 β_z 为保证收敛的正参数, s 表示DMP相位变量, $f(s)$ 表示可调制的虚拟力项. 对于三维无人机位置控制, 本文分别在 x , y , z 三个平移自由度上构建DMP模型, 并共享同一个active goal的三维坐标作为各自由度目标.

由式 (??) 和式 (??) 可知, DMP在当前时间步给出的速度和加速度可由内部状态递推得到. 在离散执行时, 先根据当前相位和目标点计算 $\dot{z}_t$, 再得到用于状态更新的加速度量:

$$\mathbf{a}_t^{\text{DMP}} = \frac{1}{\tau} [\alpha_z(\beta_z(\mathbf{g}_{\text{active}} - \mathbf{y}_t) - \mathbf{z}_t) + \mathbf{f}_t]. \quad (36)$$

式中, $\mathbf{g}_{\text{active}}$ 表示当前执行目标, $\mathbf{y}_t$ 表示当前位置, $\mathbf{z}_t$ 表示DMP速度状态, $\mathbf{f}_t$ 表示多自由度虚拟力项. 需要强调的是, 强化学习策略并不是直接输出最终

加速度, 而是通过结构化动作调制 $\mathbf{g}_{\text{active}}$ 和 $\mathbf{f}_t$, 再由DMP动力学计算平滑的加速度指令.

为缓解接近目标点时可能出现的加速度震荡, 同时满足DMP虚拟力项随目标接近逐渐衰减的需求, 本文采用距离门控的虚拟力输出形式:

$$\mathbf{f}_t = \text{clip}(\tanh(\kappa d_t) [\mathbf{f}_{\text{DMP}}(o_t)], -f_{\max}, f_{\max}) \quad (37)$$

其中, $\mathbf{f}_{\text{DMP}}(o_t)$ 表示策略根据局部观测输出的forcing term, $d_t = \|\mathbf{g}_{\text{active}} - \mathbf{y}_t\|_2$ 表示当前位置到active goal的距离, $f_{\max}$ 为确保 κ 为距离门控系数. 当智能体远离目标时, residual forcing可以对局部绕障轨迹进行较充分的调制; 当智能体接近目标时, $\tanh(\kappa d_t)$ 抑制残差力项, 从而降低终端附近的加速度震荡.

在上述DMP动作生成框架下, 下层策略输出的完整结构化动作定义为:

$$a_t = [\Delta g_t, f_t], \quad (38)$$

其中, Δg_t 用于对当前目标点进行局部偏移, f_t 用于调制DMP forcing term. 该动作空间将传统连续路径规划问题划分为目标级偏移和轨迹级修正两个子问题, 旨在降低直接学习加速度策略时常见的过冲, 振荡和收敛困难问题.

5. Reinforcement Learning Algorithm Design

本节介绍所提出方法的具体执行与训练流程, 包括分层决策时序, 奖励函数设计, 策略更新方式和整体训练过程.

5.1. Design of Planning Environments

本节主要简述训练与实验场景设置. 考虑本文面向的现实场景, 将主要的训练场景设置为以下四类:

- 封闭场景: 空旷且有界的基础环境, 多智能体分别具有独立的起点和目标点, 用于验证基本导航与协同到达能力.

- 稀疏障碍场景: 在封闭场景中加入少量静态障碍物, 用于训练智能体对局部障碍的感知, 规避与路径调整能力.
- 稠密障碍场景: 在稀疏障碍场景的基础上进一步增加障碍物数量与形态复杂度, 使可通行区域显著收窄, 用于考察策略在受限通道中的规划与避障能力.
- 全量避障场景: 在稠密障碍场景中加入按照固定模式运动的动态障碍物, 用于评估智能体同时处理静态约束与动态风险的综合避障能力.

上述四类场景以任务成功率为依据, 通过课程学习逐步提升难度, 引导智能体依次掌握编队内避让, 静态障碍绕行和动态障碍规避能力.

5.2. Reinforcement Learning Formulation

本节给出强化学习结构构建, 状态空间与观测空间设计即算法构建的详细过程.

5.2.1. State and Observation Spaces

本节主要介绍训练过程的状态与观测空间设计. 对本文面向的多智能体协同路径规划任务, 考虑场景中存在的多架智能体状态空间可被定义为:

$$s_t = [p_t, v_t, a_t] \quad (39)$$

式中, p_t , v_t 和 a_t 分别表示所有智能体在时刻 t 的位置, 速度和加速度状态. 对于单个智能体, 其控制量输入即为其三轴加速度 $[a_x, a_y, a_z]$.

智能体依赖传感器构建观测空间, 本文构建基于智能体自身传感器观测的传感器观测, 具体组织形式如下式所示:

$$x_{ray} = [d_{t,r}, d_{t-1,r}, \Delta d_{t,r}, h_{t,r}] \quad (40)$$

式中, $d_{t,r}, d_{t-1,r}$ 表示当前方向智能体与最近障碍物之间的最小归一化距离,

5.2.2. Action Space

5.2.3. Design of Reward Function

5.3. Policy Update

综合上述几部分网络, 该部分训练策略可被分解为两阶段:

5.4. Training Procedure

6. Experiments and Analysis

本节通过对比实验和消融实验验证所提出方法的有效性.

6.1. Experimental Setup

6.2. Baseline Methods

6.3. Evaluation Metrics

6.4. Comparison Results

6.5. Ablation Study

7. Conclusion

本文研究复杂动态环境下的多无人机路径规划问题, 并提出一种结合安全引导候选路点, DMP轨迹生成和分层强化学习的路径规划框架. 后续工作将进一步考虑更真实的无人机动力学约束, 通信受限条件以及真实平台实验验证.

Example citation, See [?].

References

- [1] Leslie Lamport, *LaTeX: a document preparation system*, Addison Wesley, Massachusetts, 2nd edition, 1994.