

Graphical Abstract

A Multi-uav path planning method based on DMP hybrid reinforcement learning and safety constraints

Harry Kane

Highlights

A Multi-uav path planning method based on DMP hybrid reinforcement learning and safety constraints

Harry Kane

- Research highlight 1
- Research highlight 2

A Multi-uav path planning method based on DMP hybrid reinforcement learning and safety constraints

Harry Kane

FC Bayern Munich, , Munich, 123456, , Germany

Abstract

Abstract text.

Keywords:

1. Introduction

低空复杂环境中的多无人机协同作业正在成为巡检, 搜救, 园区配送和灾害评估等任务的重要执行方式. 一个典型的工程系统通常由地面任务平台和多架无人机构成: 任务平台根据巡检设备位置, 搜索区域, 物资投送点或灾情评估区域为各无人机分配任务目标, 无人机则在城市低空, 园区, 灾后现场, 森林和工业厂区等环境中自主飞向目标. 这些环境中往往同时存在建筑物, 树木, 设备, 临时障碍物和移动目标, 且现场状态会随人员, 车辆, 风场或任务进程变化. 因此, 工程上可以合理获得任务目标点和基本飞行边界, 却很难在飞行前获得完整, 准确且实时更新的三维可通行地图.

在上述工程背景下, 多无人机路径规划的核心矛盾不是是否知道任务目标, 而是知道任务目标后如何在未知或部分未知的现场结构中安全推进. 具体而言, 每架无人机可以获得自身位置和任务目标点在全局坐标系下的位置, 但目标点只提供任务级方向引导, 并不等价于从当前位置到目标之间的全局可行路径. 沿途障碍是否临时出现, 通道是否被遮挡, 邻近无人机会如何占用局部空间, 这些信息通常只能通过机载传感器和有限邻近状态在飞行过程中逐步获得. 因此, 本文面向的是任务目标已知但完整可通行结构未知的多无人机协同路径规划问题.

这一问题对实际飞行提出了比单纯到达目标更严格的要求。首先, 环境不完全已知使无人机不能完全依赖离线规划结果; 其次, 多架无人机同时飞行时需要同时处理环境避障和机间避让, 单机安全并不等价于系统安全; 再次, 复杂环境中的大量危险试错在工程上难以接受; 最后, 飞行轨迹还需要保持平滑和稳定, 以避免过大的转向, 震荡和控制负担。在计算资源, 通信条件和传感范围均受限的条件下, 更实际的做法是让无人机主要依靠局部感知和有限邻近信息进行实时决策。

在这样的工程条件下, 直接让强化学习策略从原始局部观测中学习飞行动作会带来较高的探索风险和不安定的轨迹行为。更实际的做法是先从局部观测中提取具有安全意义的候选引导点, 再结合无人机自身状态和邻近无人机状态选择合适的短时目标, 最后通过平滑的运动生成方式执行。本文的工作正是围绕这一需求展开, 目标是在不依赖完整全局地图的前提下, 提高多无人机在复杂动态环境中的安全性和执行稳定性。

为此, 本文提出一种异步分层路点-DMP 强化学习路径规划框架。上层候选点提议模块基于当前状态, 任务目标方向和局部环境信息, 低频生成未来若干个候选引导点。这些候选引导点不被视为必须严格跟踪的完整轨迹, 而是进入 pending goal buffer, 由后续 GAT 筛选模块和下层策略根据局部风险, 任务进度和 DMP 执行相位进行选择, 跳过, 保留或偏移。

该框架的关键在于处理候选点提议, 子目标筛选和下层 DMP 执行之间的时间尺度冲突。若候选点频繁刷新并直接替换当前目标, DMP 运动基元可能在尚未执行完成时被打断, 从而造成轨迹不连续, 目标切换抖动和训练非平稳。因此, 本文采用受控异步机制: 当前 DMP 仅执行 active goal, 新生成的候选引导点进入 pending goal buffer; 只有当 DMP phase 接近结束, 当前目标已经到达, 目标区域风险过高, 执行超时或进度停滞时, 才允许从 pending goals 中切换新的 active goal。这种机制使上层候选提议与下层 DMP 轨迹执行能够在不同时间尺度下稳定协同。

本文的主要贡献可概括为:

- 提出一种异步分层路点-DMP 强化学习框架, 使候选点提议, GAT 筛选与下层 DMP 运动基元执行能够在不同时间尺度下稳定协同。

- 设计一种基于 GAT 的候选子目标筛选与结构化动作空间, 将局部路径规划过程分解为候选路点选择, 目标点偏移和 DMP residual forcing 调制, 避免策略直接输出低层控制量带来的学习困难.
- 引入 DMP 相位感知的子目标切换机制, 通过 active goal 维护, pending goal buffer 和风险触发提前终止, 缓解 DMP 执行中断, 目标切换抖动和训练非平稳问题.

2. Related Work

2.1. Multi-UAV Path Planning

2.2. Reinforcement Learning for Motion Planning

2.3. Safety-Constrained Reinforcement Learning

3. Preliminaries

本节主要介绍本文方法所依赖的基础建模, 包括多智能体任务定义, 动态障碍环境建模, 动态运动基元以及安全约束表征.

3.1. Problem Formulation

为准确描述本文面向的主要研究问题, 将多智能体强化学习路径规划任务建模为一个多智能体马尔可夫博弈过程. 马尔可夫博弈是马尔可夫决策过程在多智能体场景下的扩展, 用于刻画多个智能体在多个动作空间中的动作决策过程. 一个马尔可夫博弈过程可以由下式表示:

$$\mathcal{G} = \langle \mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i \in \mathcal{N}}, P, \{r_i\}_{i \in \mathcal{N}}, \gamma \rangle \quad (1)$$

其中, $\mathcal{N}$ 表示当前场景下的智能体集合, $\mathcal{S}$ 表示全局状态空间, $\mathcal{A}_i$ 表示第 i 个智能体的动作空间, P 表示状态转移概率, r_i 表示第 i 个智能体的奖励函数, $\gamma \in [0, 1)$ 表示折扣因子. 对每个时间步, 各个智能体依据当前的环境观测选择自身动作, 所有智能体的联合动作共同决定环境状态转移与智能体获得的即时奖励大小. 智能体的目标是在多智能体联合交互的过程中学习最优策略, 最大化联合期望回报.

本研究中, 考虑一种多智能体在存在多类障碍物的有边界环境内的实时路径规划过程. 场景存在的障碍物类型由集合 $\mathbf{O}$ 表示:

$$\mathbf{O} = \{\mathbf{O}_{static}, \mathbf{O}_{dynamic}\} \quad (2)$$

其中, $\mathbf{O}_{static}$ 表示场景中的静态障碍物, 其差异主要体现在几何外形上. 根据几何形状的不同, 本文将静态障碍物建模为圆柱体, 球体和立方体三类, 用于模拟环境中的树木, 建筑物等固定障碍物. $\mathbf{O}_{dynamic}$ 表示环境中的动态飞行障碍物, 该类障碍物以随机方向和随机速度在环境中进行直线段运动.

3.2. Dynamic Movement Primitives

3.3. Safety Constraint Representation

4. Methodology

本节介绍所提出的异步分层路点-DMP 强化学习路径规划框架. 该框架针对部分可观条件下的多无人机实时路径规划问题, 通过局部风险感知的候选点提议, GAT-based subgoal filtering, pending goal buffer, 目标偏移, DMP residual forcing 调制和 phase-aware 子目标切换, 实现候选子目标选择与平滑轨迹执行之间的稳定协同.

4.1. Overview

4.2. sensor Sector-wise Safety-margin Reference Point Proposal

复杂动态环境中的无引导探索通常具有较高的样本复杂度和安全风险. 为降低下层策略直接从原始 sensor 观测中学习子目标选择的难度, 本文在上层引入基于局部感知的参考点提议机制. 该模块每隔固定周期 T 根据当前 sensor 观测和任务目标方向提议一组短时域参考点. 这些参考点仅作为 pending goal buffer 的候选输入, 经 GAT 编码采样之后, 交由下层 DMP 执行模块进一步优化跟踪.

给定 t 时刻智能体位置 $\mathbf{x}_t$, 速度 $\mathbf{v}_t$, 局部坐标系下的 sensor 点云 $\mathcal{O}_t = \{\mathbf{o}_i\}_{i=1}^N$ 和当前任务目标位置 $\mathbf{p}_{task,t} \in \mathbb{R}^3$, 上层模块首先将局部观测划分为有限个方向扇区, 并在每个扇区内构造 CBF-inspired 安全裕度. 随后, 系统

仅在满足当前观测安全裕度的扇区内提议参考点, 并根据安全裕度, 任务推进性, 运动连续性和可用前视距离选取 top- K 个候选. 本文将生成的参考点集合定义为

$$\mathcal{G}_t = \{\mathbf{g}_t^1, \mathbf{g}_t^2, \dots, \mathbf{g}_t^K\}. \quad (3)$$

其中, $\mathbf{g}_t^k$ 表示第 k 个候选参考点, K 表示子目标缓存集合中保留的候选数量. 生成后的 $\mathcal{G}_t$ 被写入缓存和 $\mathcal{B}_t$, 而不是直接替换当前 DMP 正在执行的 active goal. 这种异步写入方式保留了上层局部引导信息, 同时避免高频目标切换打断下层轨迹执行.

为同时编码目标点的几何位置和任务类型, 本文将第 t 个时间步的任务点表示为增广目标向量:

$$\tilde{\mathbf{g}}_t = [\mathbf{p}_{\text{task},t}^\top, I_{\text{task},t}]^\top, \quad I_{\text{task},t} \in \{0, 1\}. \quad (4)$$

其中, $\mathbf{p}_{\text{task},t} \in \mathbb{R}^3$ 表示当前任务点的三维位置, $I_{\text{task},t}$ 为任务点类型的二值标记. 本文令 $I_{\text{task},t} = 0$ 表示中间路径点, $I_{\text{task},t} = 1$ 表示任务终点. 后续涉及距离, 方向和到达条件的计算时, 仅使用几何位置 $\mathbf{p}_{\text{task},t}$; 增广表示 $\tilde{\mathbf{g}}_t$ 主要作为策略输入特征, 用于帮助智能体区分不同类型任务点的执行语义.

4.2.1. sensor Sector Decomposition

首先, 将每个 sensor 点 $\mathbf{p}_i = (x_i, y_i, z_i)$ 转换到以智能体当前位置为原点的局部坐标系, 并将可观测空间离散为 M 个方向扇区:

$$\mathcal{U}_t = \{\mathbf{u}_t^1, \mathbf{u}_t^2, \dots, \mathbf{u}_t^M\}. \quad (5)$$

其中, $\mathbf{u}_t^m$ 表示第 m 个候选方向, 并对应一个局部观测扇区 $\mathcal{S}_t^m$. 该扇区中的点云集合表示为

$$\mathcal{P}_t^m = \{\mathbf{p}_i \in \mathcal{P}_t \mid \mathbf{p}_i \in \mathcal{S}_t^m\}. \quad (6)$$

对于每个扇区, 本文统计最近障碍距离和点云数量:

$$d_{t,m}^{\min} = \min_{\mathbf{p}_i \in \mathcal{P}_t^m} \|\mathbf{p}_i\|_2, \quad c_{t,m} = |\mathcal{P}_t^m|. \quad (7)$$

若某一扇区在 sensor 可靠探测范围内没有有效点云返回, 本文将其视为当前观测下的局部空旷方向, 并令 $d_{t,m}^{\min} = r_{\text{sensor}}$, $c_{t,m} = 0$, 其中 r_{sensor} 表示 sensor 可靠探测半径. 该约定避免将局部空旷区域和不可观测区域混同. 对于接近观测边界或近距离障碍的方向, 后续通过前视步长截断进行保守处理. 这种扇区表示不描述完整环境结构, 仅用于从当前 sensor 中提取有限数量的方向安全信息.

4.2.2. CBF-inspired Sector Safety Margin

基于控制障碍函数的安全集思想, 本文为每个局部扇区定义一个 CBF-inspired safety margin. 对于第 m 个扇区, 安全裕度定义为

$$h_t^m = d_{t,m}^{\min} - r_{\text{safe}} - \tau_v \|\mathbf{v}_t\|_2. \quad (8)$$

其中, r_{safe} 为最小安全距离, $\tau_v \|\mathbf{v}_t\|_2$ 表示由当前速度引入的保守制动距离. 当智能体速度较大时, 候选参考点需要更大的前向安全余量; 当最近障碍距离较小时, 该扇区的安全裕度降低. 若 $h_t^m > 0$, 则方向 $\mathbf{u}_t^m$ 在当前观测下具有局部安全余量; 若 $h_t^m \leq 0$, 则该方向不用于参考点提议.

为便于后续候选点排序, 本文将安全裕度归一化为

$$\bar{h}_t^m = \text{clip} \left(\frac{h_t^m}{h_{\max}}, 0, 1 \right). \quad (9)$$

其中, $h_{\max}$ 为归一化尺度. $\bar{h}_t^m$ 仅表示当前观测下的局部参考点提议裕度, 不表示完整轨迹满足控制障碍函数的前向不变性.

4.2.3. Sector-wise Reference Point Proposal

为避免参考点全部落入局部安全但任务进展不足的方向, 本文进一步引入任务推进方向:

$$\hat{\mathbf{d}}_t = \frac{\mathbf{p}_{\text{task},t} - \mathbf{x}_t}{\|\mathbf{p}_{\text{task},t} - \mathbf{x}_t\|_2}. \quad (10)$$

对于候选方向 $\mathbf{u}_t^m$, 其任务推进一致性定义为

$$A_t^m = (\mathbf{u}_t^m)^\top \hat{\mathbf{d}}_t. \quad (11)$$

其中, A_t^m 越大表示该方向越有利于接近当前任务目标. 需要强调的是, $\hat{\mathbf{d}}_t$ 仅作为弱目标引导, 不表示智能体必须沿该方向直接运动.

对于满足 $h_t^m > 0$ 的安全扇区, 本文根据安全裕度确定参考点前视步长:

$$\tilde{s}_t^m = \text{clip}(\eta h_t^m, s_{\min}, s_{\max}), \quad s_t^m = \min(\tilde{s}_t^m, d_{t,m}^{\min} - r_{\text{safe}}, r_{\text{sensor}}, s_{\max}). \quad (12)$$

其中, η 为比例系数, $s_{\min}$ 和 $s_{\max}$ 分别为参考点前视距离的下界和上界. $\tilde{s}_t^m$ 表示由安全裕度得到的期望前视步长, s_t^m 表示经过当前观测边界截断后的实际参考点步长. 第二项约束用于避免参考点被放置到当前扇区最近障碍物之后, 第三项约束用于避免参考点超出 sensor 可靠探测范围, 第四项进一步保持参考点前视距离不超过预设上界. 随后, 每个安全扇区生成一个候选参考点:

$$\mathbf{g}_t^m = \mathbf{x}_t + s_t^m \mathbf{u}_t^m. \quad (13)$$

同时, 为鼓励候选点在安全前提下保持足够的短时引导长度, 本文定义可用前视距离因子:

$$L_t^m = \text{clip}\left(\frac{s_t^m}{s_{\max}}, 0, 1\right). \quad (14)$$

其中, L_t^m 越大表示该方向能够提供更充分的局部前视空间. 该项不改变安全扇区的判定, 仅在安全候选之间进行排序时偏好具有更长可用前视距离的参考点.

为选取固定数量的候选参考点, 本文定义提议引导点得分:

$$S_t^m = w_h \bar{h}_t^m + w_g A_t^m + w_v (\mathbf{u}_t^m)^\top \hat{\mathbf{v}}_t + w_l L_t^m. \quad (15)$$

其中, $\hat{\mathbf{v}}_t$ 为当前速度方向, w_h , w_g , w_v 和 w_l 分别为安全裕度, 任务推进性, 运动连续性和可用前视距离的权重. 根据式 (15) 从所有安全扇区中选取得分最高的 top- K 个参考点, 得到 $\mathcal{G}_t$. 该模块只在参考点提议阶段引入当前 sensor 观测下的局部候选点, 后续经 GAT 过滤模块处理后作为中间引导引入下层跟踪过程.

4.3. Policy-Preview Spatiotemporal Graph Attention

在候选参考点进入 DMP-RL 执行器之前, 本文首先引入图注意力网络对上层引导模块生成的局部候选参考点进行过滤与筛选, 以缓解短时局部引导可能存在的非全局最优性和参数敏感性问题. 现有基于当前距离, 运动方向和预计相遇时间的候选评价方式, 能够描述无人机, 候选参考点与邻近友机之间的瞬时几何关系. 然而, 候选参考点对应的实际运动轨迹还受到下层导航策略, 无人机当前运动状态以及 DMP 内部状态的共同影响. 因此, 仅根据候选点的几何位置难以准确判断其在下层导航策略作用下的实际可执行性. 此外, 不同无人机分别选择的局部可行候选点, 在后续联合执行过程中仍可能产生明显的时空重叠, 仅依赖当前时刻的几何关系难以充分刻画该类潜在冲突.

针对上述问题, 本文在由候选参考点, 自身智能体和邻近友机构成的异构候选图基础上, 引入冻结策略短时执行预演机制. 对于每个候选参考点, 首先利用已经完成训练的下层 SAC-DMP 导航策略, 在当前已知局部信息条件下生成有限预测时域内的闭环运动序列. 随后, 从预演序列中提取短时任务推进量, 最小安全净空, 最大执行偏差和预测末端运动状态等特征, 并将其编码到相应的候选节点中. 在此基础上, 根据候选预演轨迹与邻近友机短时预测轨迹之间的最小距离, 最小距离出现时刻和风险持续时间构造未来时空交互边, 使图注意力网络能够结合候选参考点的实际执行响应和未来多机交互关系, 对不同候选参考点进行联合评价与筛选.

4.3.1. Frozen-Policy Short-Horizon Execution Preview

为评估候选参考点与下层实际执行能力之间的匹配关系, 本文设计一种冻结策略短时执行预演机制 (Frozen-Policy Short-Horizon Execution Pre-

view, FP-SHEP). 对于无人机 i 在 t 时刻生成的第 k 个候选参考点 $\mathbf{g}_{i,k}^t$, 该机制在不改变真实环境状态的条件下, 复制当前无人机位置 $\mathbf{x}_i^t$, 速度 $\mathbf{v}_i^t$, DMP 内部状态 $\mathbf{z}_i^t$, 相位变量 s_i^t 及局部传感器观测 O_i^t , 并将候选参考点 $\mathbf{g}_{i,k}^t$ 暂时设置为预演分支中的 active goal.

为便于表述, 将无人机 i 在 t 时刻可用于短时执行预演的局部信息定义为

$$\mathcal{I}_i^t = \{\mathbf{x}_i^t, \mathbf{v}_i^t, \mathbf{z}_i^t, s_i^t, O_i^t, \mathbf{p}_{\text{task},i}^t\}. \quad (16)$$

随后, 固定已完成训练的下层导航策略参数, 在长度为 H 的有限预测时域内, 按照与真实执行过程一致的观测构造, 策略前向计算, 目标偏移与 residual forcing 调制以及 DMP 状态递推过程, 生成候选参考点条件下的短时闭环执行序列:

$$\Xi_{i,k}^{t,H} = \{(\hat{\mathbf{x}}_{i,k}^{t+h}, \hat{\mathbf{v}}_{i,k}^{t+h}, \hat{\mathbf{a}}_{i,k}^{t+h})\}_{h=1}^H. \quad (17)$$

式中, $\hat{\mathbf{x}}_{i,k}^{t+h}$, $\hat{\mathbf{v}}_{i,k}^{t+h}$ 和 $\hat{\mathbf{a}}_{i,k}^{t+h}$ 分别表示选择候选参考点 $\mathbf{g}_{i,k}^t$ 后, 第 h 个预演步对应的预测位置, 速度和 DMP 输出加速度. H 表示短时执行预演的预测步数. 对于不同候选参考点, 其短时执行序列可统一表示为

$$\Xi_{i,k}^{t,H} = \text{Preview}(\pi_\theta, \text{DMP}, \mathcal{I}_i^t, \mathbf{g}_{i,k}^t, H). \quad (18)$$

式中, π_θ 表示参数保持冻结的下层 SAC 导航策略, $\text{Preview}(\cdot)$ 表示由预测观测构造, 策略前向计算, DMP 目标与 residual forcing 调制, DMP 内部状态递推及无人机运动状态更新共同组成的短时闭环预演过程. 在预演过程中, 下层导航策略参数和 DMP 参数均不参与梯度更新, 所得执行序列仅用于候选参考点的执行特性评价, 不改变真实环境状态, 也不直接向真实无人机输出控制指令.

需要强调的是, FP-SHEP 仅利用 t 时刻已经获得的局部信息进行短时预测, 不访问完整全局地图, 也不引入当前传感器观测范围之外的未知障碍信息. 在有限预测时域内, 当前已经观测到的静态障碍物位置保持不变. 对

于能够获得位置和速度信息的动态障碍物及邻近友机, 则根据其当前运动状态进行短时运动外推. 随着无人机预测位置, 速度和 DMP 内部状态的逐步更新, 系统基于当前已知局部环境信息重新构造预测观测, 并调用冻结导航策略生成下一预演步的结构化动作. 因此, FP-SHEP 所预测的是当前局部信息条件下不同候选参考点所诱导的短时闭环执行响应, 而不是对未知未来环境状态的完整预测.

通过对短时执行序列 $\Xi_{i,k}^{t,H}$ 进行特征提取, 可以获得候选参考点对应的短时任务推进量, 最小安全净空, 最大执行偏差和预测末端速度等执行特征. 由此, 原始候选参考点由仅包含局部几何信息的静态位置表示扩展为包含下层导航策略实际运动响应的执行感知候选表示, 为后续候选节点特征构造和多无人机未来时空交互关系建模提供依据.

4.3.2. Candidate Set and Heterogeneous Graph Formulation

根据上层局部参考点提议模块的输出, 无人机 i 在 t 时刻获得的候选参考点集合表示为

$$\mathcal{G}_i^t = \{\mathbf{g}_{i,1}^t, \mathbf{g}_{i,2}^t, \dots, \mathbf{g}_{i,K}^t\}. \quad (19)$$

式中, $\mathbf{g}_{i,k}^t$ 表示无人机 i 在 t 时刻生成的第 k 个候选参考点, K 表示候选参考点数量. 上述候选点仅作为后续 FP-SHEP 执行预演和图注意力筛选的输入, 不直接替换当前 DMP 正在执行的 active goal.

将候选参考点, 自身智能体和邻近友机建模为以无人机 i 为中心的局部异构图. 该图可表示为

$$\mathcal{H}_i^t = (\mathcal{V}_i^t, \mathcal{E}_i^t, \mathcal{X}_i^t, \mathcal{Z}_i^t). \quad (20)$$

式中, $\mathcal{H}_i^t$ 表示无人机 i 在 t 时刻构建的局部候选异构图, $\mathcal{V}_i^t$ 表示节点集合, $\mathcal{E}_i^t$ 表示边集合, $\mathcal{X}_i^t$ 表示节点特征集合, $\mathcal{Z}_i^t$ 表示边特征集合.

图节点集合表示为

$$\mathcal{V}_i^t = \left\{ \mathbf{v}_{\text{null}}^t, \mathbf{v}_{\text{agent},i}^t, \{\mathbf{v}_{i,k}^t\}_{k=1}^K, \{\mathbf{v}_{\text{align},j}^t\}_{j \in \mathcal{N}_i^t} \right\}. \quad (21)$$

式中, $\mathbf{v}_{\text{null}}^t$ 表示空引导节点, 即当前时刻不需要引入额外的局部参考点. $\mathbf{v}_{\text{agent},i}^t$ 表示自身智能体节点. $\mathbf{v}_{i,k}^t$ 表示第 k 个候选参考点节点. $\mathbf{v}_{\text{align},j}^t$ 表示邻近友机 j 对应的友机节点. $\mathcal{N}_i^t$ 表示无人机 i 当前能够感知或通信到的邻近友机集合. 自身智能体节点与所有候选节点连接, 邻近友机节点与满足未来时空交互条件的候选节点连接.

4.3.3. Local Conflict-Aware Heterogeneous Candidate Graph

在图神经网络中, 节点特征用于刻画节点自身的属性信息, 为后续消息传递与注意力权重计算提供基础. 考虑到本文构建的节点建模方式, 节点特征应能够反映局部几何信息, 风险信息, 任务相关属性及候选点在冻结下层策略作用下的短时执行特性. 具体节点特征设计如下.

1. 空引导节点 $\mathbf{v}_{\text{null}}^t$:

该节点表示当前时刻不需要考虑额外的局部引导点, 直接将任务终点作为待选引导. 其特征向量定义为

$$h_{\text{null}}^t = [\theta_t^{\text{goal}}, r_t^{\text{goal}}, s_t^{\text{goal}}]. \quad (22)$$

式中, θ_t^{goal} 表示任务目标相对于机体坐标系的方向角, r_t^{goal} 表示当前位置到任务目标的剩余距离, s_t^{goal} 表示目标方向对应的局部安全评分.

2. 智能体节点 $\mathbf{v}_{\text{agent},i}^t$:

该节点用于编码无人机自身运动状态和当前局部感知信息. 其特征向量定义为

$$h_{\text{agent},i}^t = [\mathbf{v}_i^t, r_i^t, \theta_i^t, \mathbf{v}_i^{t-1}, \mathcal{S}_i^t]. \quad (23)$$

式中, $\mathbf{v}_i^t$ 表示无人机当前速度向量, r_i^t 和 θ_i^t 分别表示任务目标相对无人机的距离和方向, $\mathbf{v}_i^{t-1}$ 表示上一时刻的速度向量, $\mathcal{S}_i^t$ 表示当前时刻各个 sensor 扇区的风险评分.

3. 候选引导节点 $\mathbf{v}_{i,1}^t, \dots, \mathbf{v}_{i,K}^t$:

该类节点用于编码候选参考点的局部几何属性及其在冻结下层策略作用下的短时执行特性. 根据 FP-SHEP 生成的短时执行序列 $\Xi_{i,k}^{t,H}$, 首先定义候选参考点对应的短时任务推进量为

$$\Delta d_{i,k}^{t,H} = \|\mathbf{p}_{\text{task},i}^t - \mathbf{x}_i^t\|_2 - \|\mathbf{p}_{\text{task},i}^t - \hat{\mathbf{x}}_{i,k}^{t+H}\|_2. \quad (24)$$

式中, $\Delta d_{i,k}^{t,H}$ 用于描述无人机在候选参考点引导下经过 H 个预演步后, 相对于任务目标所取得的实际距离推进.

候选预演轨迹在当前已知局部环境中的最小安全净空定义为

$$c_{i,k}^{t,\min} = \min_{1 \leq h \leq H} d_{\text{obs}}(\hat{\mathbf{x}}_{i,k}^{t+h}, O_i^t). \quad (25)$$

式中, $d_{\text{obs}}(\cdot)$ 表示预测位置与当前局部观测中已知障碍物或环境边界之间的最小距离.

为描述冻结下层策略执行候选参考点时产生的转向偏差和轨迹超调, 定义最大执行偏差为

$$e_{i,k}^{t,\perp} = \max_{1 \leq h \leq H} \text{dist}(\hat{\mathbf{x}}_{i,k}^{t+h}, \overline{\mathbf{x}_i^t \mathbf{g}_{i,k}^t}). \quad (26)$$

式中, $\text{dist}(\cdot)$ 表示预测位置到当前位置与候选参考点所构成局部参考线段的垂直距离.

预测时域末端速度定义为

$$v_{i,k}^{t,H} = \|\hat{\mathbf{v}}_{i,k}^{t+H}\|_2. \quad (27)$$

因此, 第 k 个候选参考点的节点特征定义为

$$h_{i,k}^t = [\mathbf{p}_{i,k}^t, \|\mathbf{p}_{i,k}^t\|_2, \theta_{i,k}, l_{i,k}^t, s_{i,k}^t, \Delta d_{i,k}^{t,H}, c_{i,k}^{t,\min}, e_{i,k}^{t,\perp}, v_{i,k}^{t,H}]. \quad (28)$$

式中, $\mathbf{p}_{i,k}^t$ 表示候选参考点在无人机 i 机体坐标系下的位置, 其二范数表示候选参考点距离. $\theta_{i,k}$ 表示候选参考点对应的 sensor 扇区标记. $l_{i,k}^t$ 表示根据候选点几何位置计算的任务推进距离. $s_{i,k}^t$ 表示候选方向

的局部风险评分. $\Delta d_{i,k}^{t,H}$, $c_{i,k}^{t,\min}$, $e_{i,k}^{t,\perp}$ 和 $v_{i,k}^{t,H}$ 分别表示由 FP-SHEP 得到的短时实际推进量, 最小安全净空, 最大执行偏差和预测末端速度. 其中, $l_{i,k}^t$ 描述候选点自身的几何推进能力, 而 $\Delta d_{i,k}^{t,H}$ 描述冻结下层策略执行该候选点后取得的实际短时推进效果. 二者分别从候选几何属性和下层执行响应两个层面刻画候选参考点的任务推进能力.

4. 友方节点 $\mathbf{v}_{\text{align},j}^t$:

该节点用于编码无人机 i 的邻近友机 j 的相对运动状态, 帮助图网络识别可能与候选执行轨迹产生交互的其他智能体. 其节点特征定义为

$$h_{\text{align},j}^t = [\theta_{\text{align},j}^t, r_{\text{align},j}^t, \mathbf{v}_{\text{align},j}^t]. \quad (29)$$

式中, $\theta_{\text{align},j}^t$ 表示邻近友机 j 相对于无人机 i 的方位角, $r_{\text{align},j}^t$ 表示两架无人机之间的相对距离, $\mathbf{v}_{\text{align},j}^t$ 表示友机 j 相对于无人机 i 的速度向量.

完成图结构中的节点设计后, 还需要进一步构造节点之间的边连接关系, 从而刻画不同类型节点之间的信息传递关系. 本文构建的边连接不表示真实物理连接, 而是描述不同节点之间的局部关联关系. 异构图中的边主要包括 agent-proposal 边和 proposal-align 边, 分别用于描述自身智能体与候选参考点之间的运动连续性, 以及候选执行轨迹与邻近友机预测轨迹之间的未来时空交互关系.

Agent-proposal edge features. Agent-proposal 边主要用于刻画智能体当前运动状态与候选参考点之间的方向关联关系. 对于无人机 i 及其第 k 个候选参考点 $\mathbf{g}_{i,k}^t$, 将对应的边特征定义为

$$e_{\text{agent},k}^t = [s_{\text{smooth},i,k}^t]. \quad (30)$$

式中, $s_{\text{smooth},i,k}^t$ 用于衡量无人机当前运动方向与候选参考点方向之间的一致程度, 其具体计算方式为

$$s_{\text{smooth},i,k}^t = \frac{(\mathbf{v}_i^t)^\top (\mathbf{g}_{i,k}^t - \mathbf{x}_i^t)}{\|\mathbf{v}_i^t\|_2 \|\mathbf{g}_{i,k}^t - \mathbf{x}_i^t\|_2 + \varepsilon}. \quad (31)$$

其中, ε 为用于避免分母为零的较小正数. 当 $s_{\text{smooth},i,k}^t$ 接近 1 时, 表示候选参考点方向与无人机当前速度方向具有较高的一致性, 选择该候选点能够保持较好的运动连续性. 当该值较小时, 表示无人机需要进行较大幅度的方向调整. 考虑到短时任务推进量, 安全净空和执行偏差等执行特征已经由 FP-SHEP 提取并编码到候选节点中, agent-proposal 边仅保留方向平滑性特征, 以避免节点特征与边特征之间的信息重复.

Proposal-align edge features. Proposal-align 边用于刻画候选参考点对应的预演轨迹与邻近友机预测轨迹之间的未来时空占据关系. 与仅根据候选点位置和友机瞬时状态计算预计相遇时间的方式不同, 本文利用 FP-SHEP 生成的候选条件短时执行序列 $\Xi_{i,k}^{t,H}$, 对无人机 i 选择候选参考点 $\mathbf{g}_{i,k}^t$ 后的运动趋势进行有限时域预测.

由短时执行序列 $\Xi_{i,k}^{t,H}$ 提取无人机 i 的候选预演位置序列

$$\hat{\mathcal{X}}_{i,k}^{t,H} = \{\hat{\mathbf{x}}_{i,k}^{t+h}\}_{h=1}^H. \quad (32)$$

对于邻近友机 j , 根据 t 时刻能够获得的位置 $\mathbf{x}_j^t$ 和速度 $\mathbf{v}_j^t$, 在有限预测时域内采用短时恒速模型构造其预测位置序列

$$\hat{\mathbf{x}}_j^{t+h} = \mathbf{x}_j^t + h\Delta t \mathbf{v}_j^t, \quad h = 1, 2, \dots, H. \quad (33)$$

式中, Δt 表示相邻预演步之间的时间间隔. 根据候选预演轨迹与友机预测轨迹之间的逐时刻相对位置, 定义第 h 个预测步对应的机间距离为

$$\hat{d}_{i,k;j}^{t+h} = \|\hat{\mathbf{x}}_{i,k}^{t+h} - \hat{\mathbf{x}}_j^{t+h}\|_2. \quad (34)$$

进一步定义预测时域内最小机间距离对应的预演步为

$$h_{i,k;j}^{*,t} = \arg \min_{1 \leq h \leq H} \hat{d}_{i,k;j}^{t+h}. \quad (35)$$

由此, 选择候选参考点 $\mathbf{g}_{i,k}^t$ 后的预计最小相遇时间和预计最小间距分别表示为

$$\hat{t}_{i,k;j}^t = h_{i,k;j}^{*,t} \Delta t, \quad (36)$$

$$\hat{d}_{i,k;j}^t = \min_{1 \leq h \leq H} \hat{d}_{i,k;j}^{t+h}. \quad (37)$$

仅使用最小相遇时间和最小间距能够描述两条轨迹之间最显著的接近状态, 但难以区分瞬时接近与持续时空占据. 为进一步刻画候选执行过程中的冲突持续程度, 定义风险持续时间为

$$\hat{T}_{i,k;j}^{t,\text{risk}} = \Delta t \sum_{h=1}^H \mathbb{I}(\hat{d}_{i,k;j}^{t+h} < d_{\text{safe}}). \quad (38)$$

式中, d_{safe} 表示无人机之间的预设安全距离, $\mathbb{I}(\cdot)$ 表示指示函数. 当两架无人机在第 h 个预测步的距离小于 d_{safe} 时, 该预测步被计入风险持续时间. 因此, $\hat{T}_{i,k;j}^{t,\text{risk}}$ 能够描述候选预演轨迹与友机预测轨迹之间持续接近, 平行贴近及局部交叉占据等未来时空冲突特征.

综合上述指标, 本文将 proposal-align 边特征定义为

$$e_{i,k;\text{align},j}^t = [\hat{t}_{i,k;j}^t, \hat{d}_{i,k;j}^t, \hat{T}_{i,k;j}^{t,\text{risk}}]. \quad (39)$$

式中, $\hat{t}_{i,k;j}^t$ 表示候选预演轨迹与友机预测轨迹达到最小间距的预计时间, $\hat{d}_{i,k;j}^t$ 表示预测时域内的最小机间距离, $\hat{T}_{i,k;j}^{t,\text{risk}}$ 表示两架无人机处于风险距离范围内的累计持续时间. 该设计在保留原预计相遇时间和预计最小间距语义的基础上, 进一步引入候选执行轨迹对应的风险持续信息, 使图网络能够区分瞬时接近与持续时空占据冲突.

为避免对未来运动不存在明显交互关系的友机构建冗余边, 本文根据候选预演轨迹与友机预测轨迹之间的未来最小距离确定 proposal-align 边的连接关系. 当满足

$$\hat{d}_{i,k;j}^t < d_{\text{align}}, \quad (40)$$

时, 在候选节点 $\mathbf{v}_{i,k}^t$ 与友机节点 $\mathbf{v}_{\text{align},j}^t$ 之间构建 proposal-align 边. 与根据候选点和友机当前位置之间的静态距离构建边相比, 该方式能够保留当前距离较远但未来运动轨迹可能发生交汇的友机关系, 同时削弱当前距离较近但运动趋势逐渐分离的无效交互关系.

4.3.4. Policy-Preview Edge-Enhanced GAT Selector

按照上述节点及边特征构造规则, 可以得到无人机 i 在 t 时刻对应的局部异构候选图 $\mathcal{H}_i^t$. 其节点集合与边集合分别表示为

$$\mathcal{V}_i^t = \{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{N_v}\}, \quad (41)$$

$$\mathcal{E}_i^t = \{\epsilon_1, \epsilon_2, \dots, \epsilon_{N_e}\}, \quad (42)$$

式中, N_v 和 N_e 分别表示当前局部异构图中的节点数量和边数量. 节点集合包括空引导节点, 自身智能体节点, 候选参考点节点及邻近友机节点. 边集合包括用于描述当前运动方向连续性的 agent-proposal 边, 以及用于描述候选执行轨迹与友机预测轨迹之间未来时空关系的 proposal-align 边.

由于不同类型节点和不同类型边具有不同的原始特征维度及物理语义, 本文分别采用节点类型相关 MLP 和边类型相关 MLP 进行特征映射. 对于图中的第 n 个节点及节点 n 与节点 m 之间的边, 其初始隐状态表示为

$$\mathbf{h}_n^0 = \phi_{\tau(n)}(h_n^t) \in \mathbb{R}^{d_h}, \quad \mathbf{z}_{nm}^t = \psi_{\rho(n,m)}(e_{nm}^t) \in \mathbb{R}^{d_e}. \quad (43)$$

式中, $\tau(n)$ 表示节点 n 对应的节点类型, $\rho(n,m)$ 表示边 (n,m) 对应的边类型. $\phi_{\tau(n)}(\cdot)$ 和 $\psi_{\rho(n,m)}(\cdot)$ 分别表示节点类型相关和边类型相关的 MLP 映射函数. d_h 和 d_e 分别表示节点隐特征维度和边隐特征维度. 该映射能够在保留不同节点及边物理语义的基础上, 将其转换为适用于后续图注意力计算的连续隐空间表示.

在第 l 层图注意力计算中, 边特征与边两端节点特征共同参与未归一化注意力系数计算

$$\eta_{nm}^l = \text{LeakyReLU} \left(\mathbf{a}^{l\top} [\mathbf{W}_s^l \mathbf{h}_n^l \parallel \mathbf{W}_t^l \mathbf{h}_m^l \parallel \mathbf{W}_e^l \mathbf{z}_{nm}^t] \right). \quad (44)$$

式中, $\mathbf{W}_s^l$, $\mathbf{W}_t^l$ 和 $\mathbf{W}_e^l$ 分别表示源节点, 目标节点和边特征对应的线性映射矩阵, $\mathbf{a}^l$ 表示可学习的注意力向量, $\parallel$ 表示特征拼接操作. 对于节点 n 的邻居节点 $m \in \mathcal{N}(n)$, 将未归一化注意力系数归一化为

$$\alpha_{nm}^l = \frac{\exp(\eta_{nm}^l)}{\sum_{q \in \mathcal{N}(n)} \exp(\eta_{nq}^l)}. \quad (45)$$

节点 n 在第 $l+1$ 层的特征更新表示为

$$\mathbf{h}_n^{l+1} = \sigma \left(\sum_{m \in \mathcal{N}(n)} \alpha_{nm}^l (\mathbf{W}_v^l \mathbf{h}_m^l + \mathbf{W}_z^l \mathbf{z}_{nm}^t) \right). \quad (46)$$

式中, $\mathbf{W}_v^l$ 和 $\mathbf{W}_z^l$ 分别表示邻居节点特征与边特征对应的可学习映射矩阵, $\sigma(\cdot)$ 表示非线性激活函数. 对于候选参考点节点, 其邻居主要包括自身智能体节点以及满足未来交互条件 $\hat{d}_{i,k,j}^t < d_{\text{align}}$ 的友机节点. 因此, agent-proposal 边与 proposal-align 边均能够通过边隐特征 $\mathbf{z}_{nm}^t$ 参与注意力权重计算和候选节点消息更新.

节点状态更新后, 汇总空引导节点和所有候选参考点节点的最终隐特征:

$$\mathcal{V}_{i,\text{sel}}^t = \{\mathbf{v}_{\text{null}}^t, \mathbf{v}_{i,1}^t, \dots, \mathbf{v}_{i,K}^t\}. \quad (47)$$

利用输出 MLP 对各可选节点的最终隐特征进行打分:

$$q_{i,k}^t = \psi_{\text{out}}(\mathbf{h}_{i,k}^L), \quad k \in \{\text{null}, 1, \dots, K\}. \quad (48)$$

候选节点对应的归一化选择概率为

$$P_{i,k}^t = \frac{\exp(q_{i,k}^t)}{\sum_{m \in \{\text{null}, 1, \dots, K\}} \exp(q_{i,m}^t)}. \quad (49)$$

最终选择的候选节点索引表示为

$$k_i^{*,t} = \arg \max_k P_{i,k}^t. \quad (50)$$

相应的候选参考点表示为

$$\mathbf{g}_{i,\text{sel}}^t = \begin{cases} \mathbf{p}_{\text{task},i}^t, & k_i^{*,t} = \text{null}, \\ \mathbf{g}_{i,k_i^{*,t}}^t, & k_i^{*,t} \in \{1, \dots, K\}. \end{cases} \quad (51)$$

Spatiotemporal overlap regularization. 上述 proposal-align 边能够描述本机候选预演轨迹与邻近友机当前运动趋势之间的未来交互关系. 为进一步抑制不同无人机分别选择局部可行但联合执行时存在明显时空重叠的候选参考点, 本文根据不同候选预演分支构造候选组合时空重叠代价.

对于无人机 i 的第 k 个候选参考点和无人机 j 的第 l 个候选参考点, 定义

$$O_{i,k;j,l}^t = \frac{1}{H} \sum_{h=1}^H \frac{[d_{\text{safe}} - \|\hat{\mathbf{x}}_{i,k}^{t+h} - \hat{\mathbf{x}}_{j,l}^{t+h}\|_2]_+}{d_{\text{safe}}}. \quad (52)$$

式中, $[\cdot]_+ = \max(\cdot, 0)$ 表示正部函数. 当两条候选预演轨迹在相同预测时刻的机间距离小于 d_{safe} 时, 对应时刻产生正的时空重叠代价. $O_{i,k;j,l}^t$ 越大, 表示两个候选执行分支在有限预测时域内的时空重叠程度越显著.

根据 GAT 输出的候选选择概率, 定义时空重叠正则项为

$$\mathcal{L}_{\text{overlap}} = \frac{1}{|\mathcal{P}^t|} \sum_{(i,j) \in \mathcal{P}^t} \sum_{k=1}^K \sum_{l=1}^K P_{i,k}^t P_{j,l}^t O_{i,k;j,l}^t. \quad (53)$$

式中, $\mathcal{P}^t$ 表示当前训练批次中的有效邻近无人机对集合. 当两架无人机同时对未来轨迹明显重叠的候选参考点赋予较高选择概率时, $\mathcal{L}_{\text{overlap}}$ 相应增大. 该正则项仅作用于上层 GAT 训练过程, 不改变冻结 SAC-DMP 策略的动作输出.

因此, 上层候选筛选模块的训练目标表示为

$$\mathcal{L}_{\text{upper}} = \mathcal{L}_{\text{select}} + \lambda_{\text{overlap}} \mathcal{L}_{\text{overlap}}. \quad (54)$$

式中, $\mathcal{L}_{\text{select}}$ 表示候选选择任务对应的基本优化目标, λ_{overlap} 表示时空重叠正则项的权重. 在上层候选筛选模块训练过程中, FP-SHEP 仅提供候选执行序列和相应执行特征, 上层损失不反向更新冻结的下层 SAC-DMP 策略参数.

Selected waypoint interface. 需要说明的是, GAT 输出的候选参考点 $\mathbf{g}_{i,\text{sel}}^t$ 不直接替换当前 DMP 正在执行的 active goal, 而是首先写入 pending goal buffer:

$$\mathbf{g}_{i,\text{pending}}^t \leftarrow \mathbf{g}_{i,\text{sel}}^t. \quad (55)$$

后续根据当前 active goal 的执行进度, DMP phase 及局部风险状态判断是否完成 active goal 与 pending goal 之间的切换. 在未满足切换条件时, 下层 DMP 继续执行当前 active goal. 当当前运动基元执行完成, active goal 已经到达, 当前引导方向风险超过阈值, 执行过程出现超时或连续时域内缺少有效推进时, pending goal 才被更新为新的 active goal. 该异步管理方式能够避免上层候选参考点刷新直接中断当前 DMP 运动基元, 从而保持下层轨迹执行的连续性.

4.4. A DMP based method for UAV navigation

DMP 的优势在于能够生成平滑且具有收敛特性的运动轨迹. 为将其融入多无人机强化学习路径规划任务, 本文将 DMP 作为低层动作生成器, 将强化学习策略的学习目标从直接拟合低层控制量转化为对 DMP 轨迹的目标调制和强制力调制. 对于单个自由度, DMP 的二阶点动态模型可写为:

$$\tau \dot{z} = \alpha_z(\beta_z(g - y) - z) + f(s), \quad (56)$$

$$\tau \dot{y} = z. \quad (57)$$

其中, y 表示当前自由度的位置, z 表示缩放后的速度状态, g 表示当前自由度的目标值, τ 为时间尺度参数, α_z 和 β_z 为保证收敛的正参数, s 表示 DMP 相位变量, $f(s)$ 表示可调制的虚拟力项. 对于三维无人机位置控制, 本文分别在 x, y, z 三个平移自由度上构建 DMP 模型, 并共享同一个 active goal 的三维坐标作为各自由度目标.

由式 (46) 和式 (47) 可知, DMP 在当前时间步给出的速度和加速度可由内部状态递推得到. 在离散执行时, 先根据当前相位和目标点计算 $\dot{z}_t$, 再得到用于状态更新的加速度量:

$$\mathbf{a}_t^{\text{DMP}} = \frac{1}{\tau} [\alpha_z(\beta_z(\mathbf{g}_{\text{active}} - \mathbf{y}_t) - \mathbf{z}_t) + \mathbf{f}_t]. \quad (58)$$

式中, $\mathbf{g}_{\text{active}}$ 表示当前执行目标, $\mathbf{y}_t$ 表示当前位置, $\mathbf{z}_t$ 表示 DMP 速度状态, $\mathbf{f}_t$ 表示多自由度虚拟力项. 需要强调的是, 强化学习策略并不是直接输出最终加速度, 而是通过结构化动作调制 $\mathbf{g}_{\text{active}}$ 和 $\mathbf{f}_t$, 再由 DMP 动力学计算平滑的加速度指令.

为缓解接近目标点时可能出现的加速度震荡, 同时满足 DMP 虚拟力项随目标接近逐渐衰减的需求, 本文采用距离门控的虚拟力输出形式:

$$\mathbf{f}_t = \text{clip}(\tanh(\kappa d_t) [\mathbf{f}_{\text{DMP}}(o_t)], -f_{\max}, f_{\max}) \quad (59)$$

其中, $\mathbf{f}_{\text{DMP}}(o_t)$ 表示策略根据局部观测输出的 forcing term, $d_t = \|\mathbf{g}_{\text{active}} - \mathbf{y}_t\|_2$ 表示当前位置到 active goal 的距离, $f_{\max}$ 为确保 κ 为距离门控系数. 当智能体远离目标时, residual forcing 可以对局部绕障轨迹进行较充分的调制; 当智能体接近目标时, $\tanh(\kappa d_t)$ 抑制残差力项, 从而降低终端附近的加速度震荡.

在上述 DMP 动作生成框架下, 下层策略输出的完整结构化动作定义为:

$$a_t = [\Delta g_t, f_t], \quad (60)$$

其中, Δg_t 用于对当前目标点进行局部偏移, f_t 用于调制 DMP forcing term. 该动作空间将传统连续路径规划问题划分为目标级偏移和轨迹级修正两个子问题, 旨在降低直接学习加速度策略时常见的过冲, 振荡和收敛困难问题.

5. Reinforcement Learning Algorithm Design

本节介绍所提出方法的具体执行与训练流程, 包括分层决策时序, 奖励函数设计, 策略更新方式和整体训练过程.

5.1. Design of Planning Environments

本节主要简述训练与实验场景设置. 考虑本文面向的现实场景, 将主要的训练场景设置为以下四类:

- 封闭场景: 空旷且有界的基础环境, 多智能体分别具有独立的起点和目标点, 用于验证基本规划与协同到达能力.
- 稀疏障碍场景: 在封闭场景中加入少量静态障碍物, 用于训练智能体对局部障碍的感知, 规避与路径调整能力.
- 稠密障碍场景: 在稀疏障碍场景的基础上进一步增加障碍物数量与形态复杂度, 使可通行区域显著收窄, 用于考察策略在受限通道中的规划与避障能力.
- 全量避障场景: 在稠密障碍场景中加入按照固定模式运动的动态障碍物, 用于评估智能体同时处理静态约束与动态风险的综合避障能力.

上述四类场景以任务成功率为依据, 通过课程学习逐步提升难度, 引导智能体依次掌握编队内避让, 静态障碍绕行和动态障碍规避能力.

5.2. Reinforcement Learning Formulation

本节给出强化学习结构构建, 状态空间与观测空间设计即算法构建的详细过程.

5.2.1. State and Observation Spaces

本节主要介绍训练过程的状态与观测空间设计. 对本文面向的多智能体协同路径规划任务, 考虑场景中存在的多架智能体状态空间可被定义为:

$$s_t = [p_t, v_t, a_t] \quad (61)$$

式中, p_t , v_t 和 a_t 分别表示所有智能体在时刻 t 的位置, 速度和加速度状态. 对于单个智能体, 其控制量输入即为其三轴加速度 $[a_x, a_y, a_z]$.

智能体依赖传感器构建观测空间, 本文构建基于智能体自身传感器观测的传感器观测, 具体组织形式如下式所示:

$$x_{ray} = [d_{t,r}, d_{t-1,r}, \Delta d_{t,r}, h_{t,r}] \quad (62)$$

式中, $d_{t,r}$, $d_{t-1,r}$ 表示当前方向智能体与最近障碍物之间的最小归一化距离,

5.2.2. Action Space

5.2.3. Design of Reward Function

5.3. Policy Update

综合上述几部分网络, 该部分训练策略可被分解为两阶段:

5.4. Training Procedure

6. Experiments and Analysis

本节通过对比实验和消融实验验证所提出方法的有效性.

6.1. Experimental Setup

6.2. Baseline Methods

6.3. Evaluation Metrics

6.4. Comparison Results

6.5. Ablation Study

7. Conclusion

本文研究复杂动态环境下的多无人机路径规划问题, 并提出一种结合安全引导候选路点, DMP 轨迹生成和分层强化学习的路径规划框架. 后续工作将进一步考虑更真实的无人机动力学约束, 通信受限条件以及真实平台实验验证.

Example citation, See [1].

References

- [1] Leslie Lamport, *L^AT_EX: a document preparation system*, Addison Wesley, Massachusetts, 2nd edition, 1994.